

S 02. IZDVAJANJE ZNAČAJKI

Cilj ovog dijela je pretvoriti peptidne sekvence iz pripremljenog skupa podataka u numeričke značajke koje će se koristiti za treniranje modela strojnog učenja. Za svaku peptidnu sekvencu izračunat će se bioinformatičke značajke, uključujući duljinu sekvence, neto naboj, prosječnu hidrofobnost i aminokiselinski sastav (AAC). Dobivene značajke poslužit će kao ulazni podaci u fazi modeliranja i evaluacije klasifikacijskih modela.

1. Uvoz biblioteke i funkcija

U ovom dijelu učitavaju se biblioteke potrebne za rad s tabličnim podacima te funkcija `extract_features` iz datoteke `features.py`. Ta se funkcija koristi za izračun bioinformatičkih značajki iz peptidnih sekvenci.

```
# Uvoz biblioteke pandas za rad s tabličnim podacima.
import pandas as pd

# Uvoz sys modula za dodavanje putanje do src direktorija.
import sys

# Dodavanje src direktorija u Python putanju.
sys.path.append("/content")

# Uvoz funkcije za izračun značajki.
from features import extract_features
```

S Opis rezultata

U ovom koraku učitane su biblioteke i funkcije potrebne za izdvajanje bioinformatičkih značajki iz peptidnih sekvenci.

Iz datoteke `features.py` uvezena funkcija `extract_features` koja će se koristiti za izračun bioinformatičkih značajki iz peptidnih sekvenci. Ova funkcija objedinjuje postupak izdvajanja značajki, poput duljine sekvence, neto naboja, prosječne hidrofobnosti i aminokiselinskog sastava (AAC), koji će predstavljati ulazne podatke za modele strojnog učenja.

2. Učitavanje pripremljenog skupa podataka

Učitava se prethodno pripremljeni skup podataka **dataset.csv**, koji će se koristiti u postupku izdvajanja bioinformatičkih značajki.

```
# Putanja do konačnog pripremljenog skupa podataka.
dataset_path = "dataset.csv"

# Učitavanje skupa podataka.
dataset = pd.read_csv(dataset_path)

# Prikaz prvih pet redaka.
dataset.head()
```

		ID	SEQUENCE	label
0		1390	CFQWQRNARKVR	1
1	Seq8055_sampling_method=Wang-et-al_AMP=0_rep2		TEETKVIDSRLVSDGYQ	0
2		1661	WLNALLHHGLNCAKGVL	1
3		1552	RLWRIVVIRVAR	1
4		1585	ILGTILGLLKSL	1

S Opis rezultata

U ovom koraku učitana je prethodno pripremljeni skup podataka **dataset.csv**, koji sadrži konačni uravnoteženi skup pozitivnih (AMP) i negativnih (non-AMP) peptida.

Prikaz prvih pet redaka potvrđuje da je datoteka uspješno učitana. Skup podataka sastoji se od tri stupca:

- **ID** – jedinstveni identifikator peptida,
- **SEQUENCE** – aminokiselinska sekvenca peptida,
- **label** – oznaka klase, pri čemu **1** označava antimikrobni peptid, a **0** neantimikrobni peptid.

Iz prikazanih primjera vidljivo je da skup sadrži obje klase peptida te da su podaci ispravno pripremljeni za sljedeći korak projekta – izdvajanje bioinformatičkih značajki (feature engineering).

3. Pregled skupa podataka

Prije izdvajanja bioinformatičkih značajki provjeravaju se dimenzije i raspodjela klase u skupu podataka kako bi se potvrdilo da je skup pravilno pripremljen za daljnju obradu.

```
# Dimenzije skupa podataka.
dataset.shape
```

```
(3344, 3)
```

```
# Broj uzoraka po klasama.
dataset["label"].value_counts()
```

```

      count
label
1      1672
0      1672

```

```
dtype: int64
```

S Opis rezultata

U ovom koraku provjerene su osnovne informacije o pripremljenom skupu podataka. Naredbom `dataset.shape` utvrđeno je da skup sadrži **3344 peptidne sekvence** raspoređene u **3 stupca** : **ID** , **SEQUENCE** i **label** .

Zatim je pomoću funkcije `value_counts()` provjerena raspodjela klasa. Rezultati pokazuju da skup sadrži **1672 antimikrobna peptida (label = 1)** i **1672 neantimikrobna peptida (label = 0)** .

Dobiveni rezultati potvrđuju da je skup podataka **uravnotežen** , odnosno da obje klase imaju jednak broj uzoraka. Takav skup predstavlja dobru osnovu za izdvajanje bioinformatičkih značajki i treniranje modela strojnog učenja.

Provjerava se sadrži li skup podataka nedostajuće vrijednosti kako bi se utvrdilo jesu li svi podaci potpuni prije izračunavanja bioinformatičkih značajki.

```
# Provjera nedostajućih vrijednosti.
dataset.isnull().sum()
```

```

      0
ID      0
SEQUENCE 0
label    0

```

```
dtype: int64
```

S Opis rezultata

U ovom koraku provjerene su nedostajuće vrijednosti pomoću naredbe

`dataset.isnull().sum()`, koja prikazuje njihov broj u svakom stupcu skupa podataka.

Rezultati pokazuju da stupci **ID**, **SEQUENCE** i **label** ne sadrže nijednu nedostajuću vrijednost, odnosno za svaki stupac dobivena je vrijednost **0**. To znači da su svi podaci potpuni i da nije potrebno provoditi dodatnu obradu prije nastavka analize.

Dobiveni rezultat potvrđuje da je skup podataka kvalitetno pripremljen te spreman za izračun bioinformatičkih značajki.

4. Izračun bioinformatičkih značajki

Iz svake peptidne sekvence izračunavaju se bioinformatičke značajke koje predstavljaju numerički opis njezinih svojstava i služe kao ulazni podaci za modele strojnog učenja.

```
# Izračun bioinformatičkih značajki za cijeli skup podataka.
features_df = extract_features(dataset)
```

```
# Prikaz prvih pet redaka.
features_df.head()
```

	ID	SEQUENCE	length	net_charge
0	1390	CFQWQRNARKVR	12	4
1	Seq8055_sampling_method=Wang-et-al_AMP=0_rep2	TEETKVIDSRLVSDGYQ	17	-2
2	1661	WLNALLHHGLNCAKGV	17	3
3	1552	RLWRIVVIRVAR	12	4
4	1585	ILGTILGLLKSL	12	1

5 rows × 26 columns

Warning: Total number of columns (26) exceeds max_columns (20) limiting to fi

S Opis rezultata

U ovom koraku za svaku peptidnu sekvencu izračunate su bioinformatičke značajke pomoću funkcije `extract_features()`. Za svaki peptid određene su značajke **length** (duljina sekvence), **net_charge** (neto naboj), **hydrophobicity** (hidrofobnost)

te **AAC (Amino Acid Composition)** , odnosno udio svaki od 20 standardnih aminokiselina u sekvenci.

Prikaz prvih pet redaka potvrđuje da su značajke uspješno izračunate. Dobiveni skup podataka sada sadrži **26 stupaca** : **ID** , **SEQUENCE** , **label** te **23 izračunate bioinformatičke značajke** .

Na dnu ispisa prikazano je upozorenje da DataFrame sadrži više stupaca nego što ih Colab može prikazati odjednom. To nije pogreška, već samo znači da su zbog preglednosti prikazani prvi stupci, dok su sve izračunate značajke uspješno spremljene u skup podataka.

5. Provjera dimenzija skupa značajki

Provjeravaju se dimenzije skupa značajki kako bi se potvrdilo da su bioinformatičke značajke uspješno dodane za sve peptidne sekvence.

```
# Provjera dimenzija skupa značajki.  
features_df.shape
```

```
(3344, 26)
```

S Opis rezultata

Dobiven je rezultat **(3344, 26)** , što znači da skup podataka sadrži **3344 peptidne sekvence** i **26 stupaca** .

Broj redaka ostao je nepromijenjen u odnosu na prethodni skup podataka, što potvrđuje da tijekom izračuna bioinformatičkih značajki nije došlo do gubitka zapisa. Istovremeno, broj stupaca povećan je na **26** jer su izvornim podacima dodane novoizračunate bioinformatičke značajke, uključujući duljinu sekvence, neto naboj, hidrofobnost i aminokiselinski sastav (AAC).

Dobiveni rezultat potvrđuje da su značajke uspješno izračunate za sve peptidne sekvence te da je skup značajki spreman za daljnju analizu i treniranje modela strojnog učenja.

6. Spremanje skupa značajki

Izračunajte bioinformatičke značajke spremaju se u datoteku `features.csv` kako bi bile dostupne za daljnje faze projekta.

```
# Spremanje skupa značajki za modeliranje.  
features_df.to_csv(  
    "features.csv",
```

```
index=False  
)
```

Opis rezultata

U ovom koraku izračunajte bioinformatičke značajke spremljene su u datoteku **features.csv** pomoću funkcije `to_csv()`. Parametar `index=False` koji se koristi je kako se redni brojevi DataFramea ne bi spremili kao dodatni stupac u datume.

Datoteka **features.csv** sadrži bioinformatičke značajke za svih **3344 peptidnih sekvenci** te predstavlja rezultat postupka izdvajanja značajki (feature engineering). Ovaj skup podataka koristit će se u sljedećim fazama projekta za treniranje, usporedbu i evaluaciju modela strojnog učenja.

S Izračun bioinformatičkih značajki

U ovom koraku svaka peptidna sekvenca pretvorena je u numerički zapis. Izračunajte duljinu sekvence, neto naboj, prosječnu hidrofobnost te aminokiselinski sastav (AAC). Ove značajke omogućuju modelima strojnog učenja da analiziraju biološka svojstva peptida i razlikuju AMP od ne-AMP sekvenci.

7. Statistika glavnih značajki

Prikazuju se osnovne statističke vrijednosti za duljinu sekvence, neto naboj i hidrofobnost kako bi se dobio uvid u raspodjelu glavnih bioinformatičkih značajki.

```
#Statistika glavnih značajki  
features_df[["length", "net_charge", "hydrophobicity"]].describe()
```

	length	net_charge	hydrophobicity
count	3344.000000	3344.000000	3344.000000
mean	26.527512	2.570873	-0.225078
std	19.956650	3.764262	0.909018
min	1.000000	-17.000000	-3.900000
25%	13.000000	0.000000	-0.716786
50%	20.000000	2.000000	-0.225000
75%	31.000000	5.000000	0.305682
max	148.000000	30.000000	3.250000

S Opis rezultata

U ovom koraku izračunate su osnovne statističke vrijednosti za tri glavne bioinformatičke značajke: **duljinu sekvence (length)**, **neto naboj (net_charge)** i **hidrofobnost (hydrophobicity)**. Za izračun je korištena funkcija `describe()`, koja prikazuje broj zapisa, srednju vrijednost, standardnu devijaciju, minimalnu i maksimalnu vrijednost te kvartile.

Rezultati pokazuju da su statistike izračunate za svih **3344 peptidnih sekvenci**. Prosječna duljina sekvence iznosi **26,53 aminokiseline**, pri čemu se duljine kreću od **1** do **148 aminokiselina**, što pokazuje da skup sadrži peptide različitih veličina.

Prosječan neto naboj iznosi **2,57**, a vrijednosti se kreću od **-17** do **30**, dok prosječna hidrofobnost iznosi **-0,225** s rasponom od **-3,90** do **3,25**. Dobiveni rezultati pokazuju da se bioinformatičke značajke razlikuju među peptidima te predstavljaju korisne ulazne podatke za modele strojnog učenja.

8. Usporedba značajki po klasama

Izračunavaju se prosječne vrijednosti duljine sekvence, neto naboja i hidrofobnosti za AMP i non-AMP peptide kako bi se usporedile njihove glavne bioinformatičke značajke.

```
#Usporedba po klasama
features_df.groupby("label")[["length", "net_charge", "hydrophobicity"]].mea
```

	length	net_charge	hydrophobicity
label			
0	31.564593	0.653110	-0.255638
1	21.490431	4.488636	-0.194518

S Opis rezultata

U ovom koraku uspoređene su prosječne vrijednosti triju glavnih bioinformatičkih značajki između **antimikrobnih peptida (AMP)** i **neantimikrobnih peptida (non-AMP)**. Podaci su grupirani prema oznakama klase (`label`), a zatim su izračunate prosječne vrijednosti za **duljinu sekvence (length)**, **neto naboj (net_charge)** i **hidrofobnost (hydrophobicity)**.

Rezultati pokazuju da su **antimikrobni peptidi u prosjeku kraći** od neantimikrobnih. Prosječna duljina AMP peptida iznosi **21,49 aminokiselina**, dok kod non-AMP

peptida iznosi **31,56 aminokiselina** .

Najveća razlika ocijenjena je kod **neto naboja** . AMP peptidi imaju prosječni neto naboj **4,49** , dok je kod non-AMP peptida znatno manji i iznosi **0,65** . Razlika je vidljiva i u **hidrofobnosti** , gdje AMP peptidi imaju prosječnu vrijednost **-0,19** , a non-AMP peptidi **-0,26** .

Dobiveni rezultati potvrđuju da se promatrane značajke razlikuju između dviju klasa te da mogu biti korisne pri razlikovanju antimikrobnih i neantimikrobnih peptida tijekom klasifikacije.

9. Graf prosječnog neto naboja po klasama

Izrađuje se stupčasti graf koji prikazuje prosječni neto naboj za AMP i non-AMP peptid. Graf vizualno potvrđuje da antimikrobni peptidi imaju znatno veći prosječni pozitivan naboj.

```
import matplotlib.pyplot as plt

# Prosječni neto naboj po klasama.
mean_charge = features_df.groupby("label")["net_charge"].mean()


plt.figure(figsize=(6,4))

plt.bar(
    ["non-AMP", "AMP"],
    mean_charge.values
)

plt.title("Prosječni neto naboj po klasama")
plt.xlabel("Klasa")
plt.ylabel("Prosječni neto naboj")

for i, value in enumerate(mean_charge.values):
    plt.text(i, value + 0.1, f"{value:.2f}", ha="center")

plt.ylim(0, 5.2) #da bi prostor iznad 4.49 bio veći malo
plt.show()
```

S Opis rezultata

U ovom koraku izrađen je stupčasti graf koji prikazuje **prosječni neto naboj** za **antimikrobne (AMP)** i **neantimikrobne (non-AMP)** peptide.

Na vodoravnoj osi prikazane su dvije klase (**non-AMP** i **AMP**), dok okomita os prikazuje prosječnu vrijednost neto naboja. Iznad svakog stupca ispisana je odgovarajuća numerička vrijednost.

Rezultati pokazuju da **non-AMP peptidi** imaju prosječni neto naboj **0,65**, dok **AMP peptidi** imaju znatno veći prosječni neto naboj od **4,49**. Graf jasno prikazuje razliku između dviju klasa i potvrđuje da su antimikrobni peptidi u prosjeku pozitivnije nabijeni od neantimikrobnih peptida.

10. Provjera postojanja datoteke features.csv

Provjerava se li datoteka Features.csv uspješno spremljena. Ova provjera potvrđuje da je skup značajki spreman za korištenje u fazi modeliranja.

```
import os

os.path.exists("features.csv")

Pravi
```

Opis rezultata

Rezultat provjere iznosi `True`, što potvrđuje da je datoteka `features.csv` uspješno spremljena i da se nalazi na očekivanoj lokaciji.

Zaključak

U ovoj bilježnici iz konačnog skupa peptidnih sekvenci uspješno su izračunate bioinformatičke značajke potrebne za primjenu modela strojnog učenja. Za svaku sekvencu određene su značajke poput duljine sekvence, neto naboja, hidrofobnosti i aminokiselinskog sastava (AAC), čime su peptidne sekvence pretvorene u numerički oblik priložen za daljnju analizu.

Dobiveni skup značajki sadrži **3344 peptidne sekvence** i **26 stupaca**, a uspješno je spremljen u datoteku `features.csv`. Završnom provjerom potvrđeno je da je datoteka ispravno spremljena te da je spremna za korištenje u sljedećoj fazi projekta.

Datoteka `features.csv` predstavlja ulazni skup podataka za treniranje i usporedbu modela **Random Forest** i **SVM** u sljedećoj bilježnici projekta.