

03. Modeling

Cilj ovog dijela rada je trenirati modele strojnog učenja za klasifikaciju peptida na AMP i non-AMP klase. Koristit će se Random Forest i Support Vector Machine (SVM), a modeli će se usporediti na temelju osnovnih klasifikacijskih metrika.

1. Uvoz biblioteka i učitavanje skupa značajki

U ovom dijelu učitavaju se biblioteke potrebne za modeliranje, uključujući funkcije za podjelu podataka, standardizaciju značajki, treniranje Random Forest i SVM modela te izračun evaluacijskih metrika. Nakon toga učitava se datoteka features.csv, koja sadrži prethodno izračunate bioinformatičke značajke.

```
# Uvoz pandas biblioteke za rad s tabličnim podacima.
import pandas as pd

# Uvoz funkcije za podjelu podataka na trening i testni skup.
from sklearn.model_selection import train_test_split

# Uvoz StandardScaler-a za skaliranje značajki.
from sklearn.preprocessing import StandardScaler

# Uvoz Random Forest klasifikatora.
from sklearn.ensemble import RandomForestClassifier

# Uvoz SVM klasifikatora.
from sklearn.svm import SVC

# Uvoz metrika za evaluaciju.
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score
```

```
features_path = "features.csv"

# Učitavanje skupa značajki.
features_df = pd.read_csv(features_path)

# Prikaz prvih pet redaka.
features_df.head()
```

	ID	SEQUENCE	length	net_charge	hydrophobicity	label	AAC_A	AAC_C	AAC_D
0	1390	CFQWQRNARKVR	12	4	-1.458333	1	0.083333	0.083333	0.000000
1	Seq8055_sampling_method=Wang-et-al_AMP=0_rep2	TEETKVIDSRLVSDGYQ	17	-2	-0.817647	0	0.000000	0.000000	0.117647
2	1661	WLNALLHHGLNCAKGVL	17	3	0.605882	1	0.117647	0.058824	0.000000
3	1552	RLWRIVVIRVAR	12	4	0.691667	1	0.083333	0.000000	0.000000
4	1585	ILGTILGLLKSL	12	1	1.816667	1	0.000000	0.000000	0.000000

5 rows × 26 columns

Warning: Total number of columns (26) exceeds max_columns (20) limiting to first (20) columns.

Opis rezultata

Učitana je datoteka **features.csv**.

Iz prikaza je vidljivo da skup podataka sadrži stupce **ID**, **SEQUENCE**, **length**, **net_charge**, **hydrophobicity**, **label** te stupce **AAC**, koji predstavljaju udio pojedinih aminokiselina u sekvenci. Vrijednost **label = 1** označava antimikrobne peptide (AMP), dok **label = 0** označava neantimikrobne peptide (non-AMP).

Prikaz također pokazuje da skup sadrži ukupno **26 stupaca**, što potvrđuje da su sve bioinformatičke značajke uspješno učitane i dostupne za daljnju obradu. Na dnu se pojavljuje poruka da je broj stupaca veći od zadanog broja za prikaz, zbog čega su u tablici prikazani samo prvi stupci. To nije pogreška, već ograničenje prikaza radi preglednosti.

2. Pregled skupa značajki

Provjeravaju se dimenzije skupa značajki kako bi se potvrdilo da su svi podaci uspješno pripremljeni za treniranje modela.

```
# Dimenzije skupa značajki.  
features_df.shape
```

```
(3344, 26)
```

✓ Opis rezultata

Dobiven je rezultat **(3344, 26)**, što znači da skup sadrži **3344 peptidne sekvence** i **26 stupaca**.

Rezultat pokazuje da tijekom izdvajanja značajki nije izgubljen nijedan zapis te da je skup podataka uspješno pripremljen za treniranje i evaluaciju modela strojnog učenja.

3. Priprema podataka

U ovom koraku ulazne značajke (**X**) odvajaju se od ciljine varijable (**y**).

```
# Ulazne značajke.  
X = features_df.drop(columns=["ID", "SEQUENCE", "label"])  
  
# Ciljna varijabla.  
y = features_df["label"]  
  
print("Dimenzije X:", X.shape)  
print("Dimenzije y:", y.shape)
```

```
Dimenzije X: (3344, 23)  
Dimenzije y: (3344,)
```

✓ Opis rezultata

Stupci **ID** i **SEQUENCE** ne koriste se za treniranje modela jer služe samo za identifikaciju peptida, odnosno predstavljaju tekstualni zapis aminokiselinske sekvence, dok je **label** ciljna varijabla koju model treba predvidjeti.

Model strojnog učenja koristi isključivo **numeričke bioinformatičke značajke**, poput **duljine sekvence (length)**, **neto naboja (net_charge)**, **hidrofobnosti (hydrophobicity)** i **aminokiselinskog sastava (AAC)**. Stupac **label** izdvojen je kao ciljna varijabla koju model treba predvidjeti.

Rezultati pokazuju da ulazne značajke **X** imaju dimenzije **(3344, 23)**, što znači da skup sadrži **3344 uzorka** i **23 bioinformatičke značajke**. Ciljna varijabla **y** ima dimenzije **(3344,)** te sadrži oznaku klase za svaki peptid (**0 – non-AMP**, **1 – AMP**).

4. Podjela na trening i testni skup

Skup podataka dijeli se na trening (80 %) i testni skup (20 %) . Trening skup koristi se za učenje modela, dok testni skup služi za procjenu uspješnosti modela na prethodno neviđenim podacima.

```
# Podjela na trening i testni skup.  
X_train, X_test, y_train, y_test = train_test_split(  
    X,  
    y,  
    test_size=0.20,  
    random_state=42,  
    stratify=y  
)  
  
print("X_train:", X_train.shape)  
print("X_test :", X_test.shape)  
print("y_train:", y_train.shape)  
print("y_test :", y_test.shape)
```

```
X_train: (2675, 23)  
X_test : (669, 23)  
y_train: (2675,)  
y_test : (669,)
```

Opis rezultata

Prilikom podjele korišten je parametar `test_size=0.20`, dok `stratify=y` osigurava da omjer **AMP** i **non-AMP** peptida ostane jednak u oba skupa. Parametar `random_state=42` omogućuje da se pri svakom pokretanju programa dobije ista podjela podataka, čime se osigurava reproduktivnost rezultata.

Rezultati pokazuju da **X_train** sadrži **2675 uzoraka** i **23 bioinformatičke značajke**, dok **X_test** sadrži **669 uzoraka** i isti broj značajki. Ciljna varijabla **y_train** sadrži **2675 oznaka klase**, a **y_test** **669 oznaka klase**. Time su podaci uspješno pripremljeni za treniranje i

evaluaciju klasifikacijskih modela.

5. Standardizacija značajki

Numeričke značajke standardiziraju se primjenom algoritma **StandardScaler**. Skaliranje je potrebno za **SVM model**, dok **Random Forest** nije osjetljiv na različite raspone vrijednosti. Parametri standardizacije određuju se isključivo na trening skupu kako bi se izbjeglo curenje informacija (*data leakage*).

```
# Kreiranje StandardScaler objekta.
scaler = StandardScaler()

# Skaliranje trening skupa.
X_train_scaled = scaler.fit_transform(X_train)

# Skaliranje testnog skupa.
X_test_scaled = scaler.transform(X_test)
```

✓ Opis rezultata

U ovom koraku provedena je standardizacija numeričkih značajki pomoću algoritma **StandardScaler**. Parametri skaliranja izračunati su na trening skupu (**X_train**) primjenom metode (`fit_transform()`), a zatim su isti parametri primijenjeni na testni skup (**X_test**) metodom (`transform()`).

Na taj način izbjegnuto je korištenje informacija iz testnog skupa tijekom pripreme podataka, čime se osigurava objektivna evaluacija modela.

Rezultat ovog koraka su standardizirani skupovi **X_train_scaled** i **X_test_scaled**. Standardizacija je nužna za **SVM model**, dok je **Random Forest** može koristiti, iako mu nije potrebna. Primjenom istog postupka na oba modela omogućena je njihova jednostavnija usporedba

6. Treniranje Random Forest modela

Kreira se **Random Forest** klasifikator s **100 stabala odlučivanja** te se trenira na trening skupu podataka. Random Forest kombinira više stabala odlučivanja kako bi povećao stabilnost modela i smanjio mogućnost prenaučivosti (*overfitting*).

```
# Kreiranje Random Forest modela.
rf_model = RandomForestClassifier(
    n_estimators=100,
    random_state=42
)

# Treniranje modela.
rf_model.fit(X_train, y_train)
```

RandomForestClassifier ⓘ ?
RandomForestClassifier(random_state=42)

✓ Opis rezultata

Rezultat prikazan ispod koda (`RandomForestClassifier(random_state=42)`) potvrđuje da je model uspješno kreiran i treniran. U ovoj fazi model još ne daje predviđanja niti evaluacijske metrike, već je pripremljen za klasifikaciju testnog skupa u sljedećim koracima.

7. Predviđanje pomoću Random Forest modela

Nakon treniranja model se koristi za predviđanje klasa peptida na testnom skupu podataka.

```
#predviđanje
# Predikcija na testnom skupu.
rf_predictions = rf_model.predict(X_test)
```

✓ Opis rezultata

U ovom koraku trenirani **Random Forest** model primijenjen je na testni skup podataka pomoću metode (`predict()`). Model je na temelju prethodno naučenih obrazaca iz bioinformatičkih značajki predvidio kojoj klasi pripada svaki peptid iz testnog skupa.

Dobivena predviđanja spremljena su u varijablu `rf_predictions`, koja sadrži predviđene oznake klase za sve uzorke iz testnog skupa. Svaka predviđena vrijednost može biti **0**, što označava neantimikrobni peptid (**non-AMP**), ili **1**, što označava antimikrobni peptid (**AMP**).

U ovom koraku rezultati predviđanja nisu ispisani na zaslon, već su spremljeni za daljnju analizu. U sljedećim koracima predviđene oznake usporedit će se sa stvarnim oznakama testnog skupa kako bi se izračunale metrike uspješnosti modela, poput točnosti, preciznosti, odziva i F1 mjere.

8. Izračun evaluacijskih metrika Random Forest modela

Izračunavaju se osnovne klasifikacijske metrike: točnost (Accuracy), preciznost (Precision), odziv (Recall) i F1-mjera. Dobivene vrijednosti služe za procjenu uspješnosti modela.

```
#osnove metrike
# Izračun osnovnih metrika.
rf_accuracy = accuracy_score(y_test, rf_predictions)
rf_precision = precision_score(y_test, rf_predictions)
rf_recall = recall_score(y_test, rf_predictions)
rf_f1 = f1_score(y_test, rf_predictions)

print("=" * 40)
print("Random Forest")
print("=" * 40)
print(f"Accuracy : {rf_accuracy:.4f}")
print(f"Precision: {rf_precision:.4f}")
print(f"Recall   : {rf_recall:.4f}")
print(f"F1-score : {rf_f1:.4f}")
print("=" * 40)
```

```
=====
Random Forest
=====
Accuracy : 0.9312
Precision: 0.9235
Recall   : 0.9401
F1-score : 0.9318
=====
```

✓ Opis rezultata

Dobiveni rezultati pokazuju da je **Random Forest** model ostvario vrlo dobre rezultate na testnom skupu podataka. Model je postigao **točnost od 93,12 %**, što znači da je ispravno klasificirao više od 90 % peptidnih sekvenci. **Preciznost iznosi 92,35 %**, odnosno većina peptida koje je model označio kao antimikrobne doista pripada toj skupini. **Odziv (Recall) od 94,01 %** pokazuje da je model uspješno prepoznao gotovo sve stvarne antimikrobne peptide, što je posebno važno u bioinformatici jer se na taj način smanjuje mogućnost propuštanja potencijalno korisnih peptida. **F1-mjera od 93,18 %** potvrđuje da model postiže dobru ravnotežu između preciznosti i odziva te da uspješno razlikuje antimikrobne od neantimikrobnih peptida. Visoke i međusobno slične vrijednosti svih evaluacijskih metrika pokazuju da model radi stabilno i pouzdano te da izračunate bioinformatičke značajke pružaju kvalitetnu osnovu za klasifikaciju peptidnih sekvenci primjenom algoritma Random Forest.

9. Treniranje SVM modela

Support Vector Machine (SVM) je algoritam strojnog učenja koji pronalazi optimalnu granicu razdvajanja između klasa. U ovom koraku kreira se SVM model s RBF jezgrom te se trenira na prethodno standardiziranim podacima. Za razliku od Random Forest modela, SVM zahtijeva standardizirane ulazne značajke jer se temelji na izračunu udaljenosti između uzoraka.

```
#treniranje modela
# Kreiranje SVM modela.
svm_model = SVC(
    kernel="rbf",
    random_state=42
)

# Treniranje modela.
svm_model.fit(X_train_scaled, y_train)
```

```
▼ SVC ⓘ ?
SVC(random_state=42)
```

✓ Opis rezultata

U ovom koraku kreiran je Support Vector Machine (SVM) model s RBF jezgrom, koji je zatim treniran na prethodno standardiziranim podacima. Tijekom treniranja model je analizirao bioinformatičke značajke, kao što su duljina sekvence, neto naboj, hidrofobnost i aminokiselinski sastav (AAC), kako bi pronašao optimalnu granicu koja najbolje razdvaja antimikrobne (AMP) od neantimikrobnih (non-AMP) peptida. Za osiguravanje ponovljivosti rezultata korišten je parametar `random_state=42`, a ispis `SVC(random_state=42)` potvrđuje da je model uspješno kreiran i istreniran. Nakon završetka treniranja model je spreman za predviđanje klasa na testnom skupu podataka i izračun evaluacijskih metrika.

10. Predviđanje pomoću SVM modela

Nakon treniranja SVM model koristi se za klasifikaciju peptida iz testnog skupa.

```
#predviđanje
# Predikcija na testnom skupu.
svm_predictions = svm_model.predict(X_test_scaled)
```

✓ Opis rezultata

U ovom koraku korišten je prethodno istrenirani **Support Vector Machine (SVM)** model za predviđanje pripadajuće klase peptida iz testnog skupa podataka. Predviđanje je provedeno nad standardiziranim testnim značajkama (`X_test_scaled`) pomoću metode `predict()`.

Dobivena predviđanja spremljena su u varijablu `svm_predictions`, koja sadrži predviđenu klasu za svaki uzorak iz testnog skupa. Ova predviđanja koristit će se u sljedećem koraku za izračun evaluacijskih metrika, odnosno procjenu uspješnosti SVM modela.

11. Izračun evaluacijskih metrika SVM modela

Kao i kod Random Forest modela, izračunavaju se točnost, preciznost, odziv i F1-mjera kako bi se procijenila uspješnost SVM modela.

```
#izracun metrike
# Izračun osnovnih metrika.
svm_accuracy = accuracy_score(y_test, svm_predictions)
svm_precision = precision_score(y_test, svm_predictions)
svm_recall = recall_score(y_test, svm_predictions)
svm_f1 = f1_score(y_test, svm_predictions)

print("=" * 40)
print("Support Vector Machine")
print("=" * 40)
print(f"Accuracy : {svm_accuracy:.4f}")
print(f"Precision: {svm_precision:.4f}")
print(f"Recall    : {svm_recall:.4f}")
print(f"F1-score  : {svm_f1:.4f}")
print("=" * 40)
```

```
=====
Support Vector Machine
=====
Accuracy : 0.9297
Precision: 0.9309
Recall    : 0.9281
F1-score  : 0.9295
=====
```

✓ Opis rezultata

Dobiveni rezultati pokazuju da je **Support Vector Machine (SVM)** model ostvario vrlo dobre rezultate na testnom skupu podataka. Model je postigao **točnost od 92,97 %**, **preciznost od 93,09 %**, **odziv od 92,81 %** i **F1-mjeru od 92,95 %**. Visoke i međusobno vrlo slične vrijednosti svih metrika pokazuju da model pouzdano razlikuje antimikrobne (AMP) od neantimikrobnih (non-AMP) peptida na temelju izračunatih bioinformatičkih značajki.

Usporedbom s **Random Forest** modelom može se uočiti da oba modela ostvaruju vrlo slične rezultate. SVM ima neznatno veću **preciznost**, dok Random Forest postiže nešto veću **točnost**, **odziv** i **F1-mjeru**. Posebno je važan veći **Recall** Random Forest modela jer pokazuje da uspješnije prepoznaje stvarne antimikrobne peptide.

Može se zaključiti da su oba modela vrlo uspješna za klasifikaciju peptida, ali je **Random Forest** ostvario nešto bolje ukupne rezultate te se može smatrati prikladnijim modelom za ovaj skup podataka.

12. Usporedba modela

Rezultati oba modela objedinjeni su u tablicu radi lakše usporedbe osnovnih klasifikacijskih metrika. Prikazane su vrijednosti točnosti (Accuracy), preciznosti (Precision), odziva (Recall) i F1-mjere (F1-score), koje omogućuju procjenu uspješnosti oba modela.

```
# Usporedba rezultata modela.
comparison = pd.DataFrame({
    "Model": ["Random Forest", "SVM"],
    "Accuracy": [rf_accuracy, svm_accuracy], #Točnost
    "Precision": [rf_precision, svm_precision], #Preciznost
    "Recall": [rf_recall, svm_recall],
    "F1-score": [rf_f1, svm_f1]
})

comparison
```

	Model	Accuracy	Precision	Recall	F1-score
0	Random Forest	0.931241	0.923529	0.940120	0.931751
1	SVM	0.929746	0.930931	0.928144	0.929535

✓ Opis rezultata

Usporedbom dobivenih rezultata vidljivo je da su **Random Forest** i **Support Vector Machine (SVM)** ostvarili vrlo slične rezultate. Random Forest postigao je **točnost od 93,12 %**, **preciznost od 92,35 %**, **odziv od 94,01 %** i **F1-mjeru od 93,18 %**, dok je SVM ostvario **točnost od 92,97 %**, **preciznost od 93,09 %**, **odziv od 92,81 %** i **F1-mjeru od 92,95 %**.

Iako je SVM ostvario neznatno veću preciznost, **Random Forest** postiže veću točnost, odziv i F1-mjeru. Posebno se ističe veći **Recall**, što znači da uspješnije prepoznaje stvarne antimikrobne peptide. Budući da su razlike između modela vrlo male, može se zaključiti da oba modela pouzdano klasificiraju peptide, ali je **Random Forest** ostvario nešto bolje ukupne rezultate.

Na temelju usporedbe može se zaključiti da su oba modela prikladna za klasifikaciju antimikrobnih peptida te postižu vrlo visoku uspješnost. Međutim, **Random Forest** pokazao se uspješnijim jer ostvaruje veću točnost, veći odziv i višu F1-mjeru, zbog čega je odabran kao najbolji model za ovaj skup podataka.

```
# Usporedba rezultata modela.
comparison = pd.DataFrame({
    "Model": ["Random Forest", "SVM"],
    "Accuracy": [rf_accuracy, svm_accuracy], #Točnost
    "Precision": [rf_precision, svm_precision], #Preciznost
    "Recall": [rf_recall, svm_recall],
    "F1-score": [rf_f1, svm_f1]
})
comparison = comparison.round(4) #na 4decimale

comparison
```

	Model	Accuracy	Precision	Recall	F1-score
0	Random Forest	0.9312	0.9235	0.9401	0.9318
1	SVM	0.9297	0.9309	0.9281	0.9295

✓ Opis rezultata

Usporedbom rezultata može se uočiti da oba modela ostvaruju vrlo visoke vrijednosti svih evaluacijskih metrika. **Random Forest** postiže nešto veću **točnost (0,9312)**, **odziv (0,9401)** i **F1-mjeru (0,9318)**, dok **SVM** ostvaruje neznatno veću **preciznost (0,9309)**. Razlike između modela su vrlo male, što pokazuje da oba modela uspješno klasificiraju antimikrobne i neantimikrobne peptide na temelju izračunatih bioinformatičkih značajki. Iako su oba modela ostvarila vrlo dobre rezultate, **Random Forest** pokazao je nešto bolju ukupnu uspješnost zahvaljujući većoj točnosti, većem odzivu i višoj F1-mjeri. Zbog toga se može zaključiti da je **Random Forest** prikladniji model za klasifikaciju antimikrobnih peptida na korištenom skupu podataka.

```
comparison_percent = comparison.copy()

for column in ["Accuracy", "Precision", "Recall", "F1-score"]:
    comparison_percent[column] = (comparison_percent[column] * 100).round(2)

comparison_percent #postotak
```

	Model	Accuracy	Precision	Recall	F1-score
0	Random Forest	93.12	92.35	94.01	93.18
1	SVM	92.97	93.09	92.81	92.95

▼ Opis rezultata

U ovom koraku rezultati **Random Forest** i **Support Vector Machine (SVM)** modela objedinjeni su u jednu tablicu radi lakše usporedbe njihovih performansi. Prikazane su vrijednosti osnovnih klasifikacijskih metrika: **točnost (Accuracy)**, **preciznost (Precision)**, **odziv (Recall)** i **F1-mjera (F1-score)**, izražene u postocima.

Iz tablice je vidljivo da je **Random Forest** ostvario **točnost od 93,12 %**, **preciznost od 92,35 %**, **odziv od 94,01 %** i **F1-mjeru od 93,18 %**, dok je **SVM** ostvario **točnost od 92,97 %**, **preciznost od 93,09 %**, **odziv od 92,81 %** i **F1-mjeru od 92,95 %**.

Usporedbom rezultata može se zaključiti da oba modela postižu vrlo visoke vrijednosti svih evaluacijskih metrika te uspješno klasificiraju antimikrobne i neantimikrobne peptide. Iako je **SVM** ostvario neznatno veću preciznost, **Random Forest** postigao je veću točnost, odziv i F1-mjeru, zbog čega je ostvario nešto bolju ukupnu uspješnost na korištenom skupu podataka.

15. Graf usporedbe modela

Izrađuje se stupčasti graf kojim se uspoređuju performanse Random Forest i SVM modela prema točnosti, preciznosti, odzivu i F1-mjeri. Graf omogućuje jednostavnu vizualnu usporedbu rezultata oba modela.

```
# Uvoz biblioteke za crtanje grafova.
import matplotlib.pyplot as plt

# Popis metrika.
metrics = ["Accuracy", "Precision", "Recall", "F1-score"]

# Vrijednosti za oba modela.
rf_values = [rf_accuracy, rf_precision, rf_recall, rf_f1]
svm_values = [svm_accuracy, svm_precision, svm_recall, svm_f1]

# Položaj stupaca.
x = range(len(metrics))
width = 0.35

# Veličina slike.
plt.figure(figsize=(8, 5))

# Random Forest stupci.
plt.bar(
    [i - width/2 for i in x],
    rf_values,
    width=width,
    label="Random Forest"
)

# SVM stupci.
plt.bar(
    [i + width/2 for i in x],
    svm_values,
    width=width,
    label="SVM"
)


# Označe osi.
plt.xticks(x, metrics)
plt.ylabel("Vrijednost")
plt.xlabel("Metrika")

# Naslov.
plt.title("Usporedba performansi Random Forest i SVM modela")

# Legenda.
plt.legend()

# Ograničenje y osi.
plt.ylim(0, 1.0)

# Prikaz grafa.
plt.show()
```



Opis rezultata

U ovom koraku izrađen je stupčasti graf kojim se uspoređuju performanse **Random Forest** i **Support Vector Machine (SVM)** modela prema osnovnim klasifikacijskim metrikama: **Accuracy**, **Precision**, **Recall** i **F1-score**. Na vodoravnoj osi prikazane su evaluacijske metrike, dok okomita os prikazuje njihove vrijednosti.

Iz grafa je vidljivo da oba modela ostvaruju vrlo slične rezultate, pri čemu su sve vrijednosti veće od **92 %**. **Random Forest** postiže nešto bolje rezultate u metrikama **Accuracy**, **Recall** i **F1-score**, dok **SVM** ostvaruje neznatno veću **Precision**.

Graf potvrđuje rezultate prikazane u prethodnoj tablici te pokazuje da oba modela uspješno klasificiraju antimikrobne i neantimikrobne peptide. Iako su razlike između modela male, **Random Forest** ostvaruje nešto bolju ukupnu uspješnost te se može smatrati prikladnijim modelom za klasifikaciju antimikrobnih peptida u ovom projektu.