

S 04. Evaluation

Cilj ovog notebooka je detaljnije evaluirati rezultate modela za klasifikaciju antimikrobnih peptida. Analizirat će se matrice zabune, klasifikacijski izvještaji i važnost značajki kako bi se bolje razumjelo ponašanje modela.

1. Uvoz biblioteka i učitavanje značajki

U ovom dijelu učitavaju se biblioteke potrebne za evaluaciju modela, uključujući funkcije za izračun matrice zabune, klasifikacijskog izvještaja te prikaz važnosti značajki. Nakon toga učitava se skup podataka Features.csv, koji sadrži sve prethodno izračunate bioinformatičke značajke.

```
# Uvoz pandas biblioteke.
import pandas as pd

# Uvoz biblioteke za crtanje grafova.
import matplotlib.pyplot as plt

# Uvoz funkcija za podjelu podataka.
from sklearn.model_selection import train_test_split

# Uvoz funkcije za skaliranje.
from sklearn.preprocessing import StandardScaler

# Uvoz modela.
from sklearn.ensemble import RandomForestClassifier
from sklearn.svm import SVC

# Uvoz evaluacijskih metrika.
from sklearn.metrics import confusion_matrix, classification_report, ConfusionMatrixDisplay
```

```
# Putanja do skupa značajki.
features_path = "features.csv"

# Učitavanje skupa značajki.
features_df = pd.read_csv(features_path)

# Prikaz prvih pet redaka.
features_df.head()
```

	ID	SEQUENCE	length	net_charge	hydrophobicity	label	AAC_A	AAC_C	AAC_D
0	1390	CFQWQRNARKVR	12	4	-1.458333	1	0.083333	0.083333	0.000000
1	Seq8055_sampling_method=Wang-et-al_AMP=0_rep2	TEETKVIDSRLVSDGYQ	17	-2	-0.817647	0	0.000000	0.000000	0.117647
2	1661	WLNALLHHGLNCAKGVL	17	3	0.605882	1	0.117647	0.058824	0.000000
3	1552	RLWRIVVIRVAR	12	4	0.691667	1	0.083333	0.000000	0.000000
4	1585	ILGTILGLLKS	12	1	1.816667	1	0.000000	0.000000	0.000000

5 rows × 26 columns

S Opis rezultata

U ovom koraku učitana je datoteka **features.csv** koja sadrži prethodno izračunate bioinformatičke značajke peptidnih sekvenci. Prikaz prvih pet redaka (`head()`) koristi se za provjeru ispravnosti učitavanja i strukture skupa podataka. Iz prikazano je vidljivo da svaki redak predstavlja jednu peptidnu sekvencu, dok stupci sadrže identifikator peptida (**ID**), aminokiselinsku sekvencu (**SEQUENCE**), bioinformatičke značajke (**length**, **net_charge**, **hydrophobicity** i **AAC**) te oznaku klase (**label**). Skup podataka sadrži ukupno **26 stupaca**, pri čemu se zbog preglednosti prikazuje samo dio njih. Dobiveni rezultat potvrđuje da je datoteka uspješno učitana i da je skup podataka spreman za daljnju evaluaciju modela.

2. Priprema podataka za evaluaciju

Kako bi rezultati bili usporedivi s prethodnim notebookom, koristi se ista podjela podataka na trening i testni skup te isti parametri modela. Podaci se ponovno dijele na trening i testni skup, a ulazne značajke standardiziraju se za potrebe SVM modela.

```
# Odvajanje ulaznih značajki od ciljne varijable.
X = features_df.drop(columns=["ID", "SEQUENCE", "label"])

# Ciljna varijabla.
y = features_df["label"]

# Podjela na trening i testni skup.
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.20,
    random_state=42,
    stratify=y
)

# Skaliranje značajki za SVM.
scaler = StandardScaler()

X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

S Opis rezultata

U ovom koraku ponovno su pripremljeni podaci za evaluaciju modela. Iz skupa podataka izdvojene su ulazne značajke (**X**) i ciljna varijabla (**y**), nakon čega je skup podijeljen na trening i testni dio u omjeru **80 : 20** primjenom istih parametara kao u prethodnoj fazi (`random_state=42` i `stratify=y`). Zatim je provedena standardizacija ulaznih značajki pomoću metode **StandardScaler** , pri čemu je skaliranje određeno na trening skupu, a zatim primijenjeno i na testni skup. U ovoj ćeliji nema numeričkog ispisa rezultata, već se podaci pripremaju za daljnju evaluaciju i analizu modela.

3. Ponovno treniranje Random Forest modela

Random Forest model ponovno se trenira koristeći iste parametre kao u prethodnom dijelu projekta. Nakon treniranja model predviđa klase peptida na testnom skupu.

```
# Treniranje Random Forest modela.
rf_model = RandomForestClassifier(
    n_estimators=100,
    random_state=42
)

rf_model.fit(X_train, y_train)

# Predikcije Random Forest modela.
rf_predictions = rf_model.predict(X_test)
```

S Opis rezultata

U ovom koraku ponovno je kreiran i treniran **Random Forest** model koristeći prethodno pripremljeni trening skup podataka. Model je postavljen s **100 stabala odlučivanja** (`n_estimators=100`) i parametrom (`random_state=42`), čime je osigurana ponovljivost rezultata. Nakon završetka treniranja model je primijenjen na testni skup podataka te su dobivena predviđanja (`rf_predictions`) za svaki uzorak. U ovoj ćeliji ne prikazuju se numerički rezultati, već se provodi treniranje modela i generiraju predviđanja koja će se koristiti u sljedećim koracima evaluacije.

4. Ponovno treniranje SVM modela

Trenira se Support Vector Machine model na standardiziranim podacima te se generiraju predviđanja za testni skup kako bi se omogućila detaljna evaluacija rezultata.

```
#za SVM
# Treniranje SVM modela.
svm_model = SVC(
    kernel="rbf",
    random_state=42
)

svm_model.fit(X_train_scaled, y_train)

# Predikcije SVM modela.
svm_predictions = svm_model.predict(X_test_scaled)
```

S Opis rezultata

U ovom koraku ponovno je kreiran i treniran **Support Vector Machine (SVM)** model koristeći prethodno standardizirani trening skup podataka. Model je postavljen s **RBF jezgrom** (`kernel="rbf"`) i parametrom `random_state=42` kako bi rezultati bili usporedivi s prethodnim dijelom projekta. Nakon završetka treniranja model je primijenjen na standardizirani testni skup te su dobivena predviđanja (`svm_predictions`) za svaki uzorak. U ovoj ćeliji ne prikazuju se numerički rezultati, već se provodi treniranje modela i generiraju predviđanja koja će se koristiti u sljedećim koracima evaluacije.


5. Matrica zabune - Random Forest

Izračunava se matrica zabune (Confusion Matrix) za Random Forest model. Matrica prikazuje broj ispravno i pogrešno klasificiranih antimikrobnih i neantimikrobnih peptida.

```
#confusion matrix.
#Random Forest confusion matrix
# Matrica zabune za Random Forest model.
rf_cm = confusion_matrix(y_test, rf_predictions)

# Prikaz matrice zabune.
ConfusionMatrixDisplay(
    confusion_matrix=rf_cm,
    display_labels=["non-AMP", "AMP"]
).plot()

plt.title("Matrica zabune - Random Forest")
plt.show()
```



S Opis rezultata

U ovom koraku izračunata je **matrica zabune (Confusion Matrix)** za **Random Forest** model. Matrica prikazuje broj ispravno i pogrešno klasificiranih **AMP** i **non-AMP** peptida te omogućuje detaljniju analizu uspješnosti klasifikacije.

Rezultati pokazuju da je model **309 non-AMP** peptida ispravno klasificirao kao **non-AMP**, a **314 AMP** peptida kao **AMP**. Pogrešno je klasificirano **26 non-AMP** peptida kao **AMP** te **20 AMP** peptida kao **non-AMP**.

Dobivena matrica pokazuje da je Random Forest ostvario vrlo dobre rezultate, s malim brojem pogrešnih klasifikacija u obje klase.

6. Matrica zabune – SVM

Prikazuje se matrica zabune za SVM model kako bi se vizualno procijenila njegova sposobnost razlikovanja dviju klasa peptida.

```
#SVM confusion matrix
# Matrica zabune za SVM model.
svm_cm = confusion_matrix(y_test, svm_predictions)


# Prikaz matrice zabune.
ConfusionMatrixDisplay(
```

```

confusion_matrix=svm_cm,
display_labels=["non-AMP", "AMP"]
).plot()

plt.title("Matrica zabune - SVM")
plt.show()

```



S Opis rezultata

U ovom koraku izračunata je **matrica zabune (Confusion Matrix)** za **Support Vector Machine (SVM)** model. Matrica prikazuje broj ispravno i pogrešno klasificiranih **AMP** i **non-AMP** peptida te omogućuje procjenu uspješnosti klasifikacije.

Rezultati pokazuju da je model **312 non-AMP** peptida ispravno klasificirao kao **non-AMP**, a **310 AMP** peptida kao **AMP**. Pogrešno su klasificirana **23 non-AMP** peptida kao **AMP** te **24 AMP** peptida kao **non-AMP**.

Dobiveni rezultati pokazuju da je **SVM** ostvario vrlo dobru uspješnost klasifikacije uz mali broj pogrešnih predviđanja. U usporedbi s **Random Forest** modelom imao je nešto manje pogrešaka pri klasifikaciji **non-AMP** peptida, ali nešto više pri klasifikaciji **AMP** peptida.

7. Classification Report – Random Forest

Izračunava se klasifikacijski izvještaj koji prikazuje preciznost (Precision), odziv (Recall), F1-mjeru i broj uzoraka za svaku klasu.

```

# Klasifikacijski izvještaj za Random Forest.
print("Random Forest")
print("=" * 50)

print(
    classification_report(
        y_test,
        rf_predictions,
        target_names=["non-AMP", "AMP"]
    )
)

```

```

Slučajna šuma
=====
podrška za precizno prisjećanje f1 rezultata

ne-AMP 0,94 0,92 0,93 335
AMP 0,92 0,94 0,93 334

točnost 0,93 669
makro prosjek 0,93 0,93 0,93 669
ponderirani prosjek 0,93 0,93 0,93 669

```

S Opis rezultata

U ovom koraku prikazan je **Classification Report** za **Random Forest** model. Izvještaj sadrži četiri osnovne metrike uspješnosti: **Precision**, **Recall**, **F1-score** i **Support** za svaku klasu.

Rezultati pokazuju da je model ostvario vrlo dobre performanse za obje klase. Za **non-AMP** peptide ostvareni su **Precision = 0,94**, **Recall = 0,92** i **F1-score = 0,93**, dok su za **AMP** peptide ostvareni **Precision = 0,92**, **Recall = 0,94** i **F1-score = 0,93**.

Ukupna **točnost (Accuracy)** modela iznosi **93 %**, pri čemu su vrijednosti **makro** i **ponderiranog prosjeka** također **0,93**. To pokazuje da model jednako dobro klasificira obje klase te postiže uravnotežene i pouzdane rezultate na testnom skupu.

10. Classification Report – SVM

Na isti način prikazuju se klasifikacijske metrike za SVM model kako bi se omogućila izravna usporedba s Random Forest modelom

```
# Klasifikacijski izvještaj za SVM.
print("Support Vector Machine")
print("=" * 50)

print(
    classification_report(
        y_test,
        svm_predictions,
        target_names=["non-AMP", "AMP"]
    )
)
```

```
Stroj potpornih vektora
=====
                podrška za precizno prisjećanje f1 rezultata

      ne-AMP 0,93 0,93 0,93 335
      AMP 0,93 0,93 0,93 334

      točnost 0,93 669
      makro prosjek 0,93 0,93 0,93 669
      ponderirani prosjek 0,93 0,93 0,93 669
```

S Opis rezultata

U ovom koraku prikazan je **Classification Report** za **Support Vector Machine (SVM)** model. Izvještaj sadrži četiri osnovne metrike uspješnosti: **Precision**, **Recall**, **F1-score** i **Support** za svaku klasu.

Rezultati pokazuju da je model ostvario vrlo dobre performanse za obje klase. Za **non-AMP** peptide ostvareni su **Precision = 0,93**, **Recall = 0,93** i **F1-score = 0,93**, dok su za **AMP** peptide također ostvareni **Precision = 0,93**, **Recall = 0,93** i **F1-score = 0,93**.

Ukupna **točnost (Accuracy)** modela iznosi **93 %**, pri čemu su vrijednosti **makro** i **ponderiranog prosjeka** također **0,93**. Dobiveni rezultati pokazuju da SVM model postiže uravnotežene i pouzdane rezultate u klasifikaciji antimikrobnih i neantimikrobnih peptida.

12. Važnost značajki (Feature Importance)

Random Forest omogućuje procjenu važnosti pojedinih bioinformatičkih značajki korištenih tijekom klasifikacije. Analiza važnosti značajki pomaže razumjeti koja svojstva peptida najviše doprinose razlikovanju antimikrobnih i neantimikrobnih peptida.

```
# Dohvaćanje važnosti značajki.
feature_importance = pd.DataFrame({
    "Feature": X.columns,
    "Importance": rf_model.feature_importances_
})

# Sortiranje prema važnosti.
feature_importance = feature_importance.sort_values(
    by="Importance",
    ascending=False
)

# Prikaz prvih 10 značajki.
feature_importance.head(10)
```

	Feature	Importance
1	net_charge	0.160260
6	AAC_E	0.096955
11	AAC_K	0.093487
5	AAC_D	0.089152
13	AAC_M	0.054361
2	hydrophobicity	0.042182
19	AAC_T	0.041506
4	AAC_C	0.041363
17	AAC_R	0.037102
0	length	0.036416

S Opis rezultata

U ovom koraku prikazana je **važnost bioinformatičkih značajki (Feature Importance)** koju je izračunao **Random Forest** model. Svakoj značajki dodijeljena je vrijednost koja pokazuje koliko je pridonijela razlikovanju antimikrobnih (**AMP**) i neantimikrobnih (**non-AMP**) peptida.

Rezultati pokazuju da je **net_charge** najvažnija značajka (**0,160260**), što znači da je neto naboj imao najveći utjecaj na odluke modela. Slijede značajke **AAC_E**, **AAC_K** i **AAC_D**, koje predstavljaju udio pojedinih aminokiselina u peptidnoj sekvenci. Među važnijim značajkama nalaze se i **hydrophobicity**, **AAC_M**, **AAC_T**, **AAC_C**, **AAC_R** te **length**.

Dobiveni rezultati pokazuju da model pri klasifikaciji koristi kombinaciju **neto naboja**, **hidrofobnosti**, **duljine sekvence** i **aminokiselinskog sastava**. Posebno se ističe **neto naboj** kao najvažnija značajka, što je u skladu s poznatim biološkim svojstvima antimikrobnih peptida. Antimikrobni peptidi najčešće su **pozitivno nabijeni**, zbog čega se mogu učinkovito vezati za **negativno nabijene membrane mikroorganizama** i ostvariti svoje antimikrobno djelovanje. Zbog toga je upravo neto naboj imao najveći utjecaj na odluke Random Forest modela.

13. Graf važnosti značajki

Prikazuje se deset najvažnijih bioinformatičkih značajki prema Random Forest modelu u obliku horizontalnog stupčastog grafikona radi lakše usporedbe njihove važnosti.

```
# Prikaz 10 najvažnijih značajki.
top_features = feature_importance.head(10)


plt.figure(figsize=(8,5))

plt.barh(
    top_features["Feature"],
    top_features["Importance"]
)

plt.gca().invert_yaxis()

plt.xlabel("Važnost")
plt.ylabel("Značajka")
plt.title("10 najvažnijih značajki prema Random Forest modelu")

plt.show()
```



S Opis rezultata

U ovom koraku prikazan je **horizontalni stupčasti graf** deset najvažnijih bioinformatičkih značajki prema **Random Forest** modelu. Graf omogućuje jednostavnu vizualnu usporedbu njihovog doprinosa klasifikaciji antimikrobnih (**AMP**) i neantimikrobnih (**non-AMP**) peptida.

Iz grafa je vidljivo da se **net_charge** jasno izdvaja kao najvažnija značajka. Nakon nje slijede **AAC_E**, **AAC_K** i **AAC_D**, dok nešto manji, ali i dalje značajan doprinos imaju **AAC_M**, **hydrophobicity**, **AAC_T**, **AAC_C**, **AAC_R** i **length**.

Graf potvrđuje rezultate prikazane u prethodnoj tablici te pokazuje da Random Forest pri klasifikaciji koristi kombinaciju **fizikalno-kemijskih svojstava** i **aminokiselinskog sastava** peptida. Takvi rezultati u skladu su s poznatim biološkim svojstvima antimikrobnih peptida, što dodatno potvrđuje da model donosi odluke na temelju smislenih bioinformatičkih značajki.

14. Analiza pogrešno klasificiranih primjera

U ovom dijelu izdvajaju se peptidi koje je Random Forest model pogrešno klasificirao. Analiza takvih primjera omogućuje bolje razumijevanje ograničenja modela i identifikaciju sekvenci koje posjeduju svojstva karakteristična objema klasama.

```
# Kopiranje testnog skupa radi analize pogrešaka.
error_analysis = features_df.loc[X_test.index, ["ID", "SEQUENCE", "label"]].copy()

# Dodavanje stvarne oznake klase.
error_analysis["true_label"] = y_test.values

# Dodavanje predikcije Random Forest modela.
error_analysis["rf_prediction"] = rf_predictions

# Izdvajanje pogrešno klasificiranih primjera.
rf_errors = error_analysis[
    error_analysis["true_label"] != error_analysis["rf_prediction"]
]

# Prikaz prvih 10 pogrešno klasificiranih primjera.
rf_errors.head(10)
```

	ID	SEQUENCE	label	true_label
2006	1304	DLVELAMLEADRMSR	1	
3262	Seq381_sampling_method=Witten&Witten_AMP=0_rep4	PGEGGKDRPFKVSIFVSRVSWHLL	0	
1333	1305	QDNYWVTQGLNILSG	1	
2230	Seq895_sampling_method=AMPlify_AMP=0_rep4	FIPTFY	0	
3085	Seq942_sampling_method=Gabere&Noble_AMP=0_rep1	RRFSLSTTIHLFKKIVRITLSTFISYTW	0	
893	36	NLVSGLIEARKYLEQLHRKLNCKV	1	
47	708	GLLSRLRDFLSDRGRRLGEKIERIGQKIKDLSEFFQS	1	
1526	1104	GEILCNLCTGLINTLENLLTTKGADKVKDYISSLCNKASGFATLC...	1	
2811	Seq963_sampling_method=AMPlify_AMP=0_rep4	IISISSKKNFKLVIL	0	
505	1586	AGETHVTMINHAGRGAPKLVVGKKLS	1	

Opis rezultata

U ovom koraku analizirani su primjeri koje je **Random Forest** model pogrešno klasificirao. Iz testnog skupa izdvojeni su peptidi kod kojih se predviđena klasa razlikuje od stvarne klase. Za svaki pogrešno klasificirani primjer prikazani su identifikator peptida (**ID**), aminokiselinska sekvenca (**SEQUENCE**), stvarna oznaka klase (**true_label**) i oznaka koju je predvidio model (**rf_prediction**).

Iz prikazanih rezultata vidljivo je da su među pogrešno klasificiranim primjerima prisutni i **lažno pozitivni** i **lažno negativni** rezultati. To